Predicción de Precios de Coches de Segunda Mano en España.

Un proyecto de Machine Learning aplicado al sector automoción

Presentado por Jorge.

Made with GAMMA

El Problema de Negocio

Trabajo en el sector de automoción desde hace ni me acuerdo. He tenido muchos trabajos y sin darme cuenta, al final casi todos estaban relacionados con la automoción.

Ese es el problema que quiero resolver: dado un coche con sus características, ¿cuánto debería valer en el mercado español de segunda mano? Para resolverlo usamos Machine Learning — concretamente regresión supervisada. Tenemos miles de anuncios reales con sus precios, y el modelo aprende de ellos para estimar el precio de cualquier coche nuevo que le presentes.

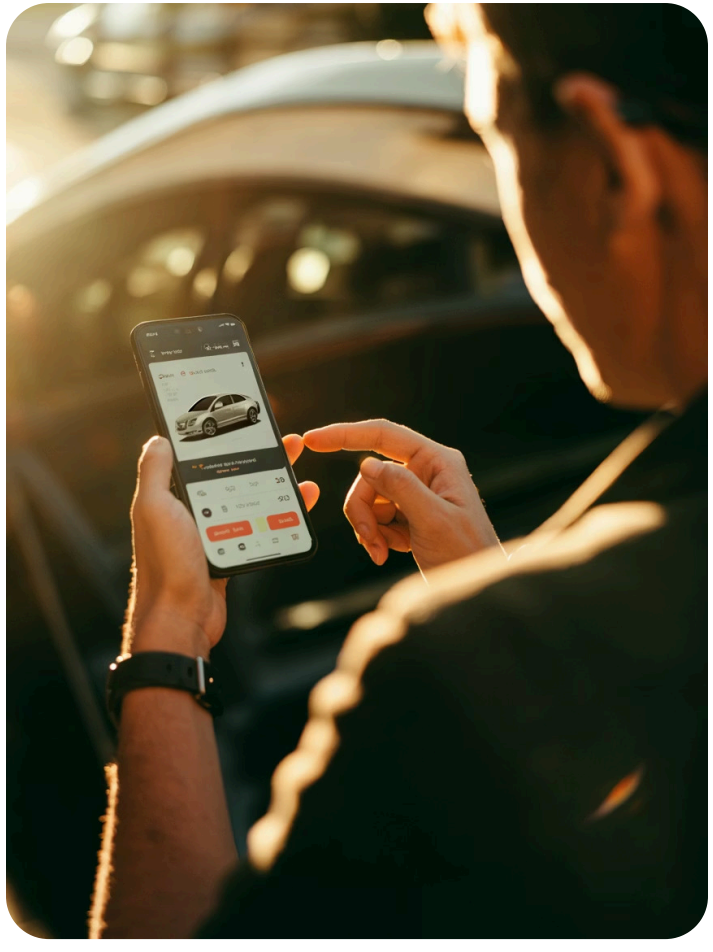

Made with GAMMA

Dataset y Estrategia de Limpieza

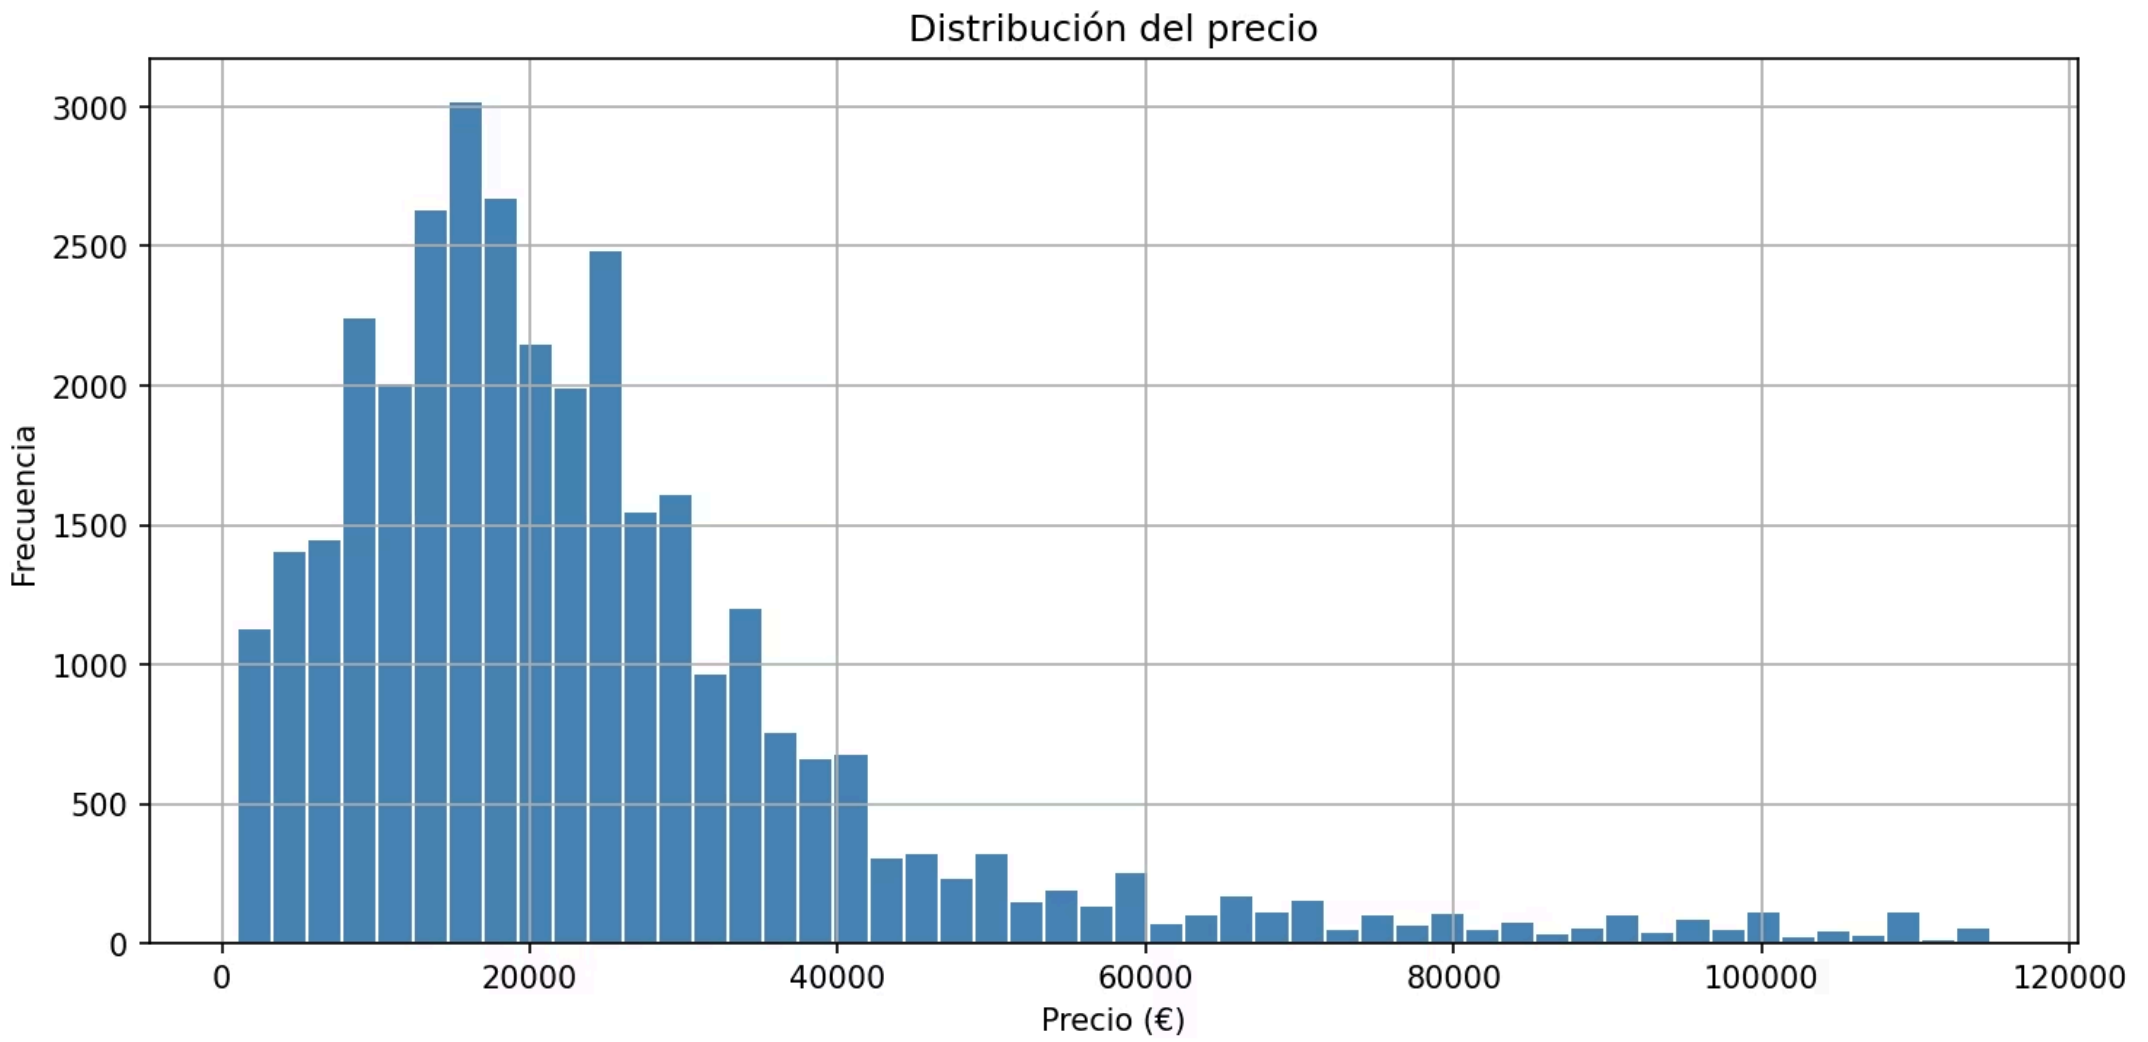

Origen de los datos

AutoScout24 — portal de venta más grande de Europa. Dataset disponible en Kaggle.

Alcance geográfico

8 países europeos: Alemania, Italia, Francia, España, Bélgica, Holanda, Austria y Luxemburgo.

Dimensiones

40.494 anuncios con 25 variables cada uno — marca, modelo, año, kilometraje, potencia, combustible, cambio, tracción y precio.

Proceso de limpieza

01

Identificación de outliers

16 millones de kilómetros (error de base de datos), Citroën C3 a 10 millones €, motores de 67.500cc, 255 asientos.

02

Gestión de missings

Tracción delantera y tapicería de tela imputados como valor por defecto. Propietarios anteriores descartados (44% missings y dato manipulable).

03

Resultado final

38.450 registros limpios — solo 5% de pérdida de datos. Dataset europeo para EDA + modelo centrado en España.

Made with GAMMA

EDA: Hallazgos Principales

¿Qué mueve el precio de un coche usado?

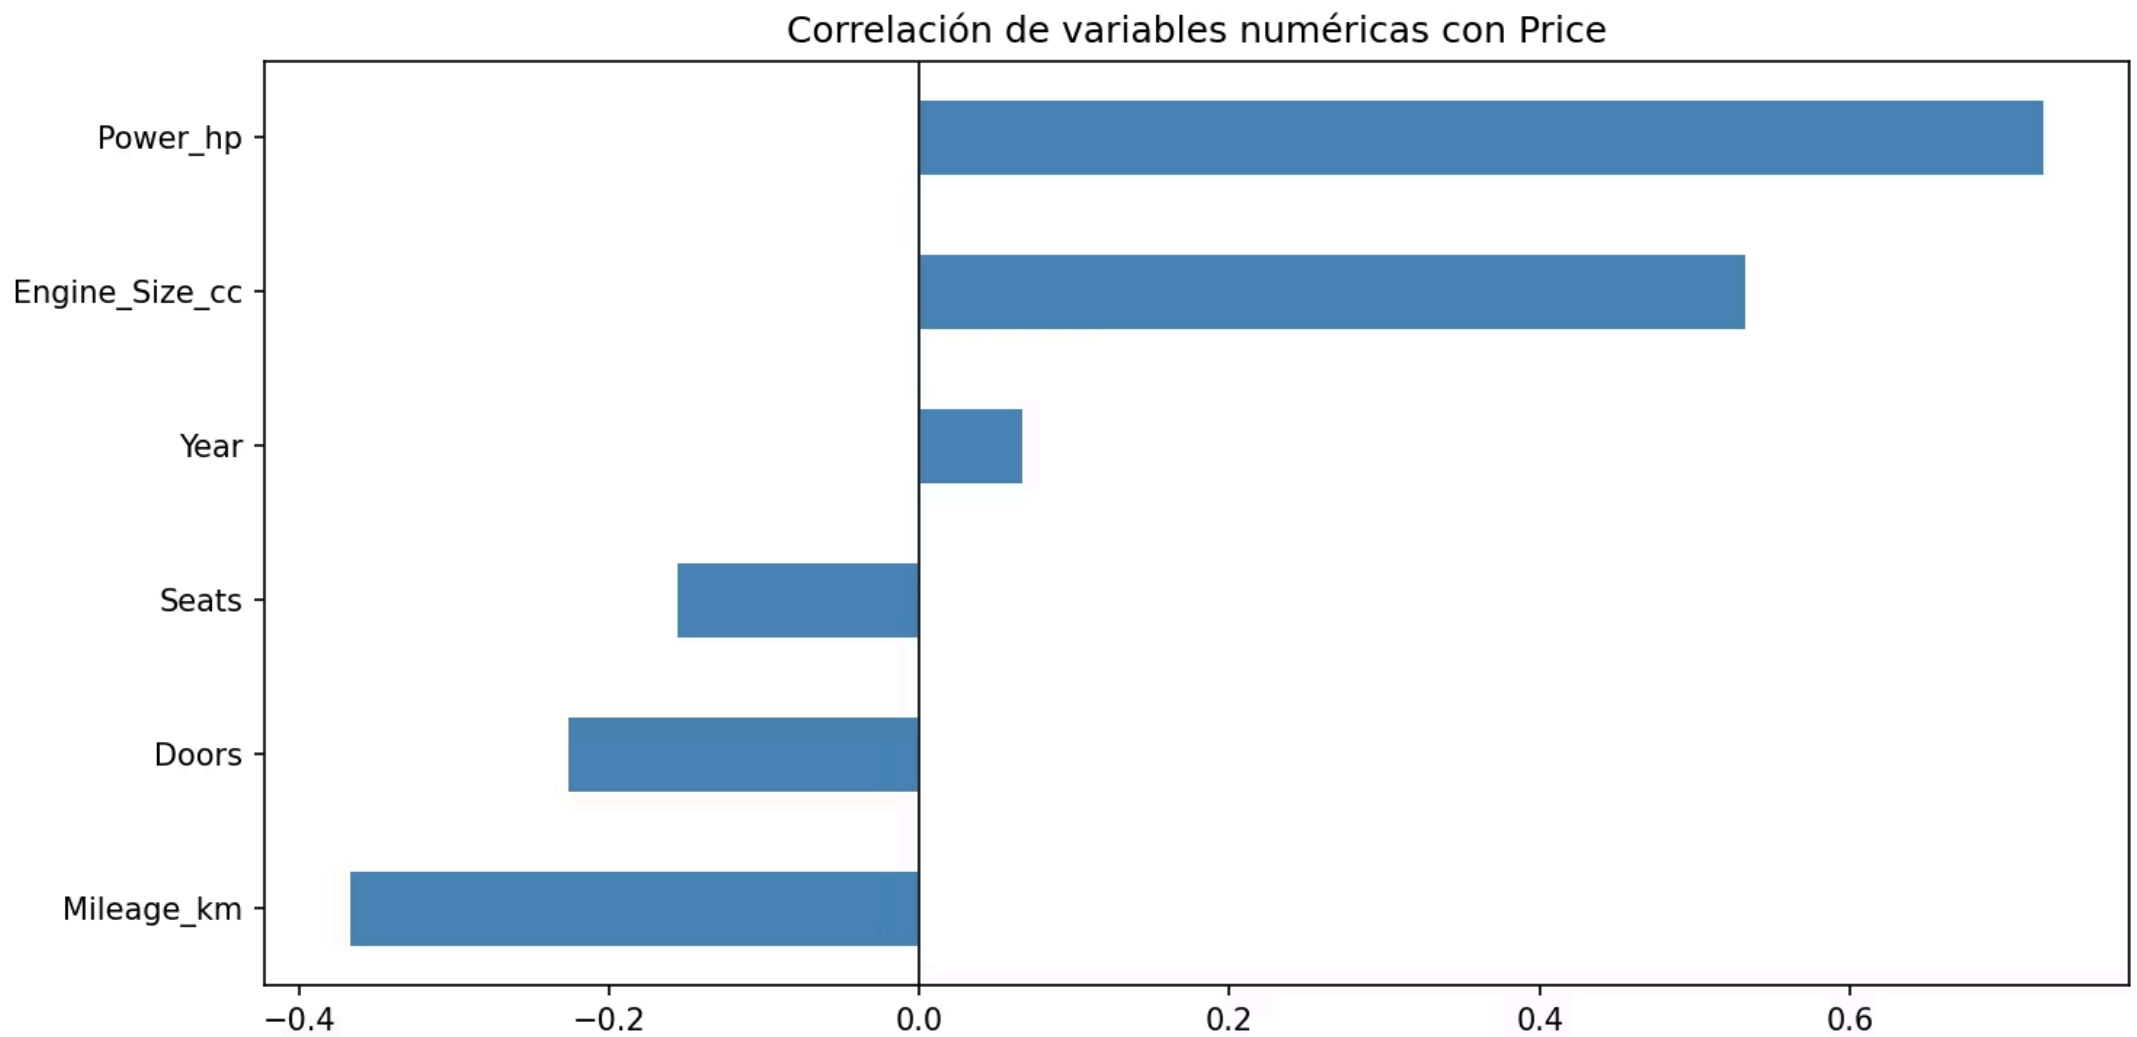

Potencia (0.73)

Más caballos, más precio. El comprador mira los cv, no los cilindros.

Kilometraje (-0.37)

Deprecia más que la antigüedad. Los coches clásicos rompen la lógica de "más viejo, más barato".

Año (0.07)

Menor impacto que el kilometraje. Además correlaciona menos de lo esperado.

Por países

Francia y Luxemburgo los precios medios más altos. España por debajo de la media europea, coherente con poder adquisitivo del mercado.

Por marcas

CUPRA lidera precio medio. BMW y Audi retienen valor. Fiat y Opel se deprecian más rápido.

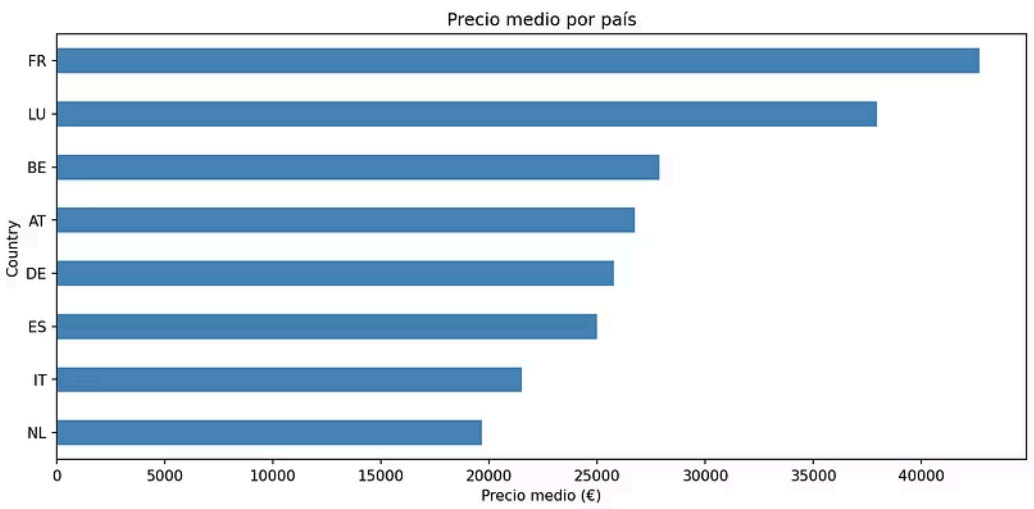

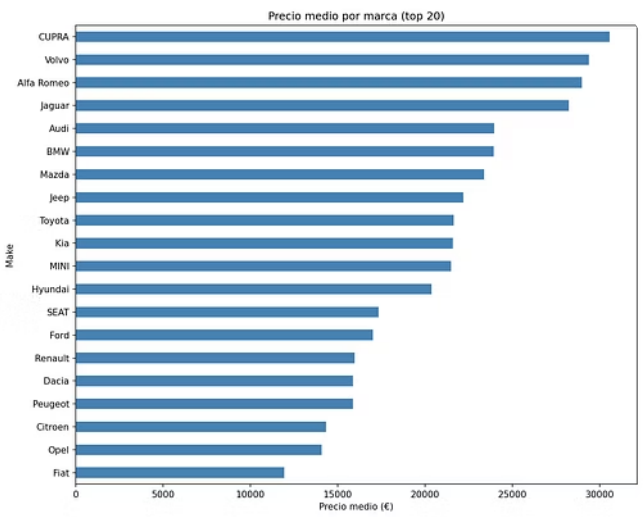

Made with GAMMA

Hipótesis verificadas

H1 — Kilometraje vs antigüedad El kilometraje deprecia más. Confirmada.

H2 — Diferencias de precio por país Francia y Luxemburgo lideran. España por debajo de la media. Confirmada.

H3 — Marcas premium retienen más valor CUPRA, BMW y Audi aguantan el precio. Fiat y Opel se hunden. Confirmada.

H4 — Influencia del combustible en el precio. Eléctricos e híbridos más caros Sí, y el diesel ha caído por debajo de la gasolina. Confirmada parcialmente.

H5 — Propietarios anteriores: descartada. 44% de missings y dato fácilmente manipulable por los vendedores. **H6 — Potencia como factor más predictivo: confirmada en el análisis.** Correlación 0.73 con el precio, la más alta de todas las variables.

Made with GAMMA

Pipeline de Machine Learning

Estrategia: Modelo centrado en España

1.373 registros tras la limpieza. Separación 80/20 train-test con random_state fijo para reproducibilidad.

1

Preprocesado

Eliminación de variables sin aportación: Condition (99% Used), Upholstery, Seller (un valor único), Model (alta cardinalidad).

2

Transformación

Encoding con get_dummies para categóricas. StandardScaler para numéricas, ajustado solo con train.

3

Validación

Validación cruzada para evitar sobreajuste y estimar error real del modelo.

Comparativa de modelos

Baseline (predecir siempre precio medio): **13.769€ MAE**

4,662€

RandomForest

Ganador en validación cruzada, con 85% de mejora sobre baseline

4,929€

GradientBoosting

Cerca del ganador

5,850€

Modelos lineales

Se quedan atrás

GridSearchCV: 81 combinaciones de hiperparámetros. Mejora marginal de 4.662€ a 4.660€. RandomForest ya bien ajustado de serie.

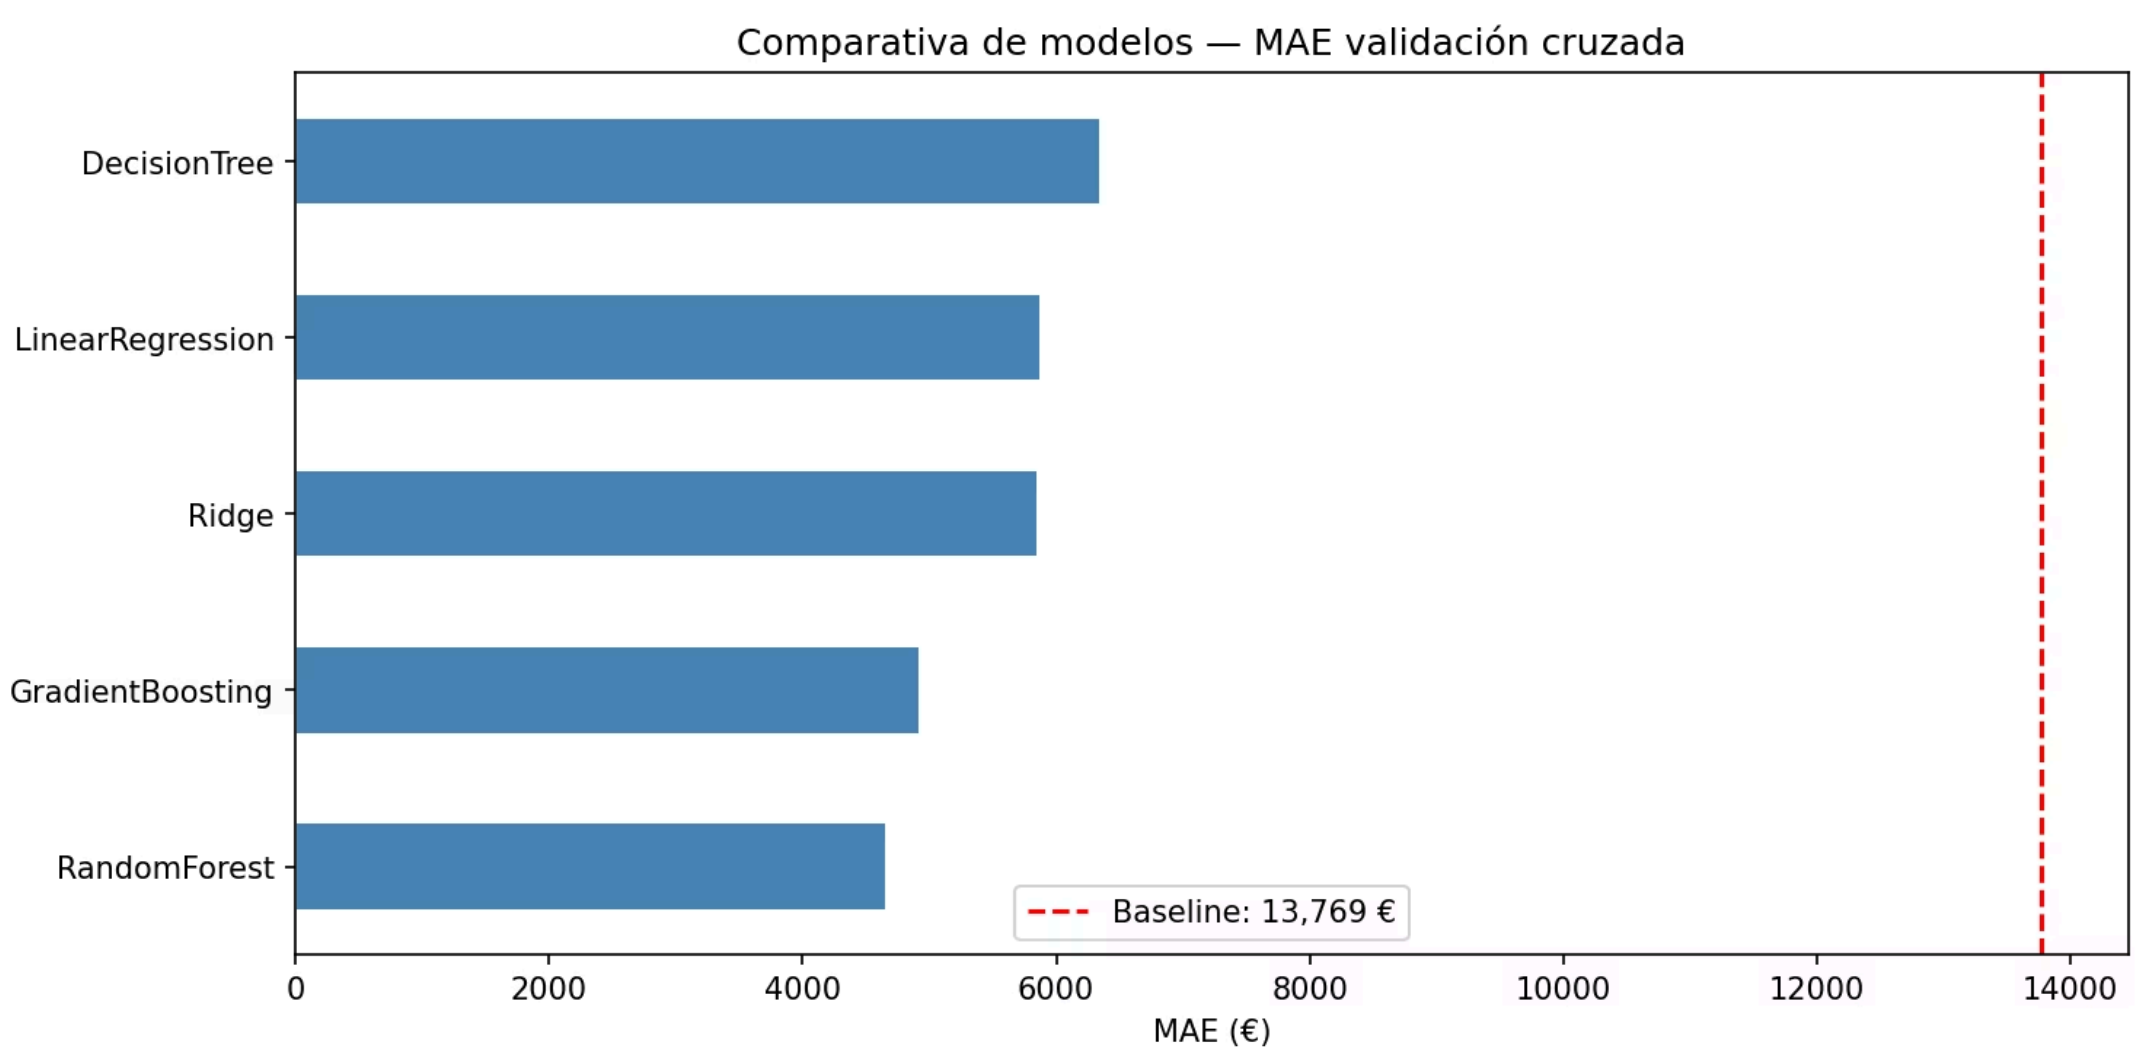

Made with GAMMA

Resultados y Conclusiones

Métricas finales contra test

4,344€

MAE

Error medio absoluto

0.850

R^2

Explica el 85% de la variabilidad del precio

Conclusiones principales

- La **potencia es el factor más determinante** del precio, seguida por kilometraje.
- El mercado español tiene **precios propios**, por debajo de la media europea.
- El modelo es **útil para el segmento mayoritario** (0-40.000€) y tiene limitaciones en gama alta.

Mejoras concretas sugeridas

Mejora 1 — Más datos españoles. Con solo 1.373 registros el modelo tiene poco donde aprender, especialmente en gama alta. Haciendo scraping de Coches.net o Wallapop conseguiría mucho más volumen y representaría mejor el mercado real español. O bien topar más los precios para centrarnos en el grueso del mercado. Me gusta más lo primero.

Mejora 2 — Recuperar el modelo del coche, tuve que descartarlo porque había 268 modelos distintos y eso generaba demasiadas columnas. Con Target Encoding — sustituir cada modelo por su precio medio histórico — se podría incluir sin ese problema. Un Golf GTI no vale lo mismo que un Golf base, y el modelo debería saberlo.

Mejora 3 — Antigüedad del anuncio, si un coche lleva 6 meses en el anuncio sin venderse, algo pasa — precio alto, problema oculto, o simplemente poca demanda. Es una señal de mercado real que este dataset no recoge pero que se podría obtener haciendo scraping con fecha de publicación.

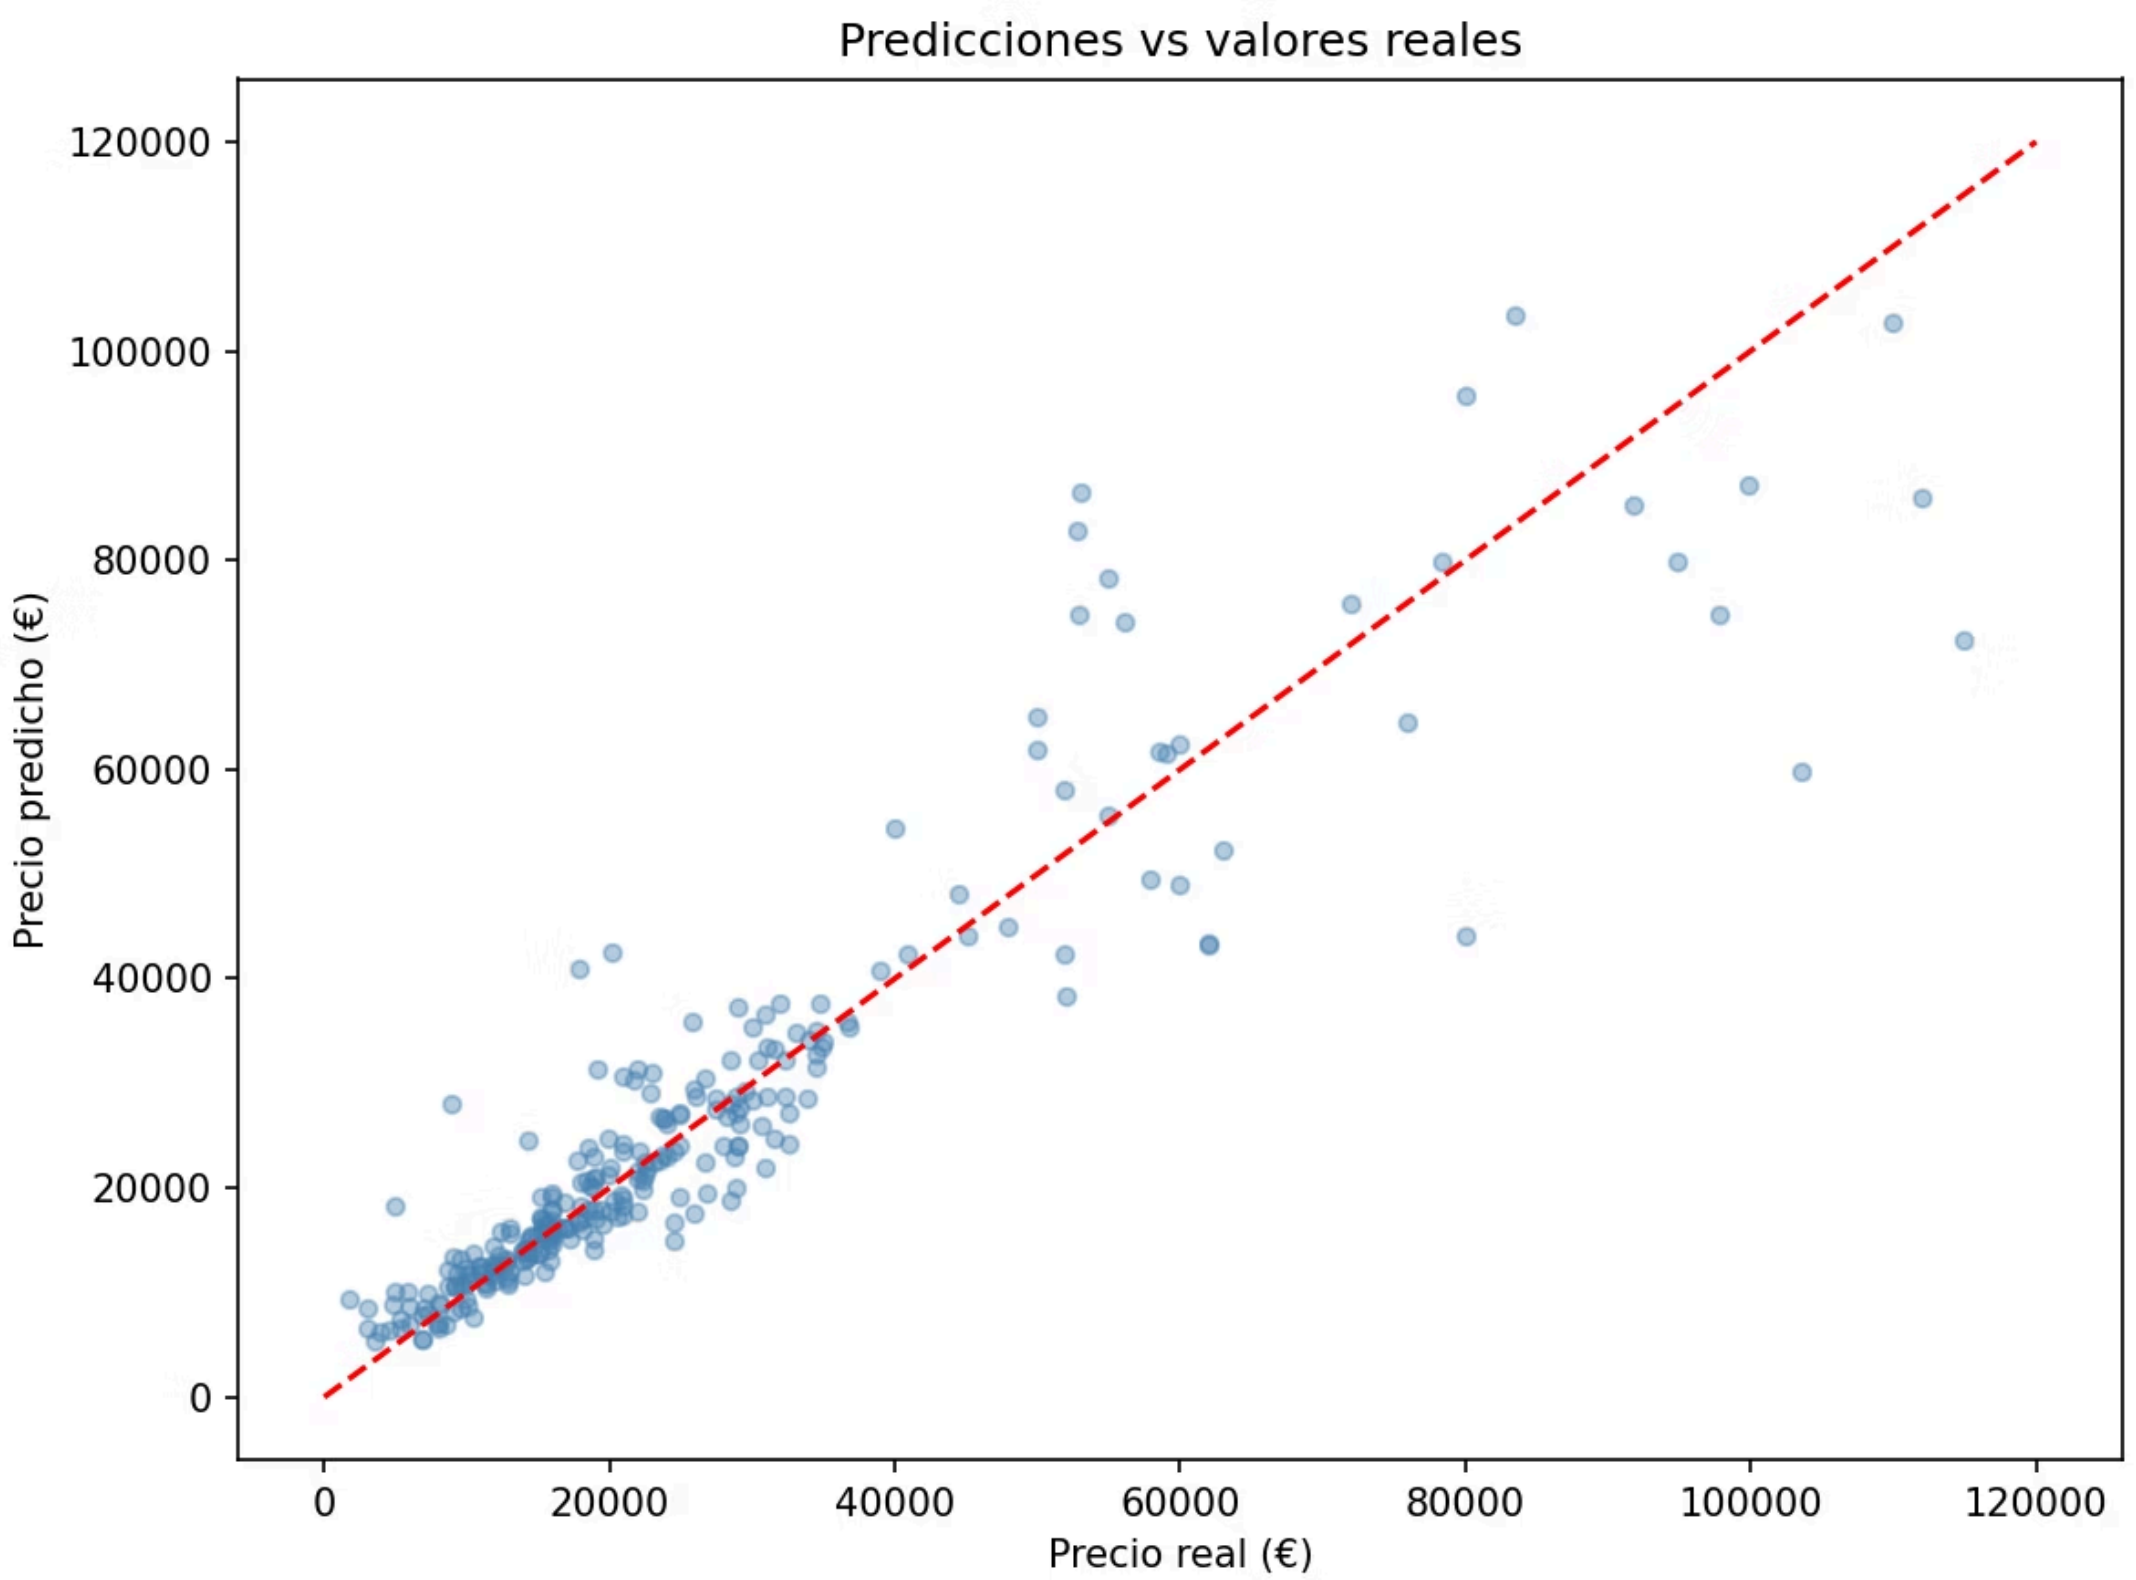

Made with GAMMA